PROJEKT DOKUMENTÁCIÓ

Adatelemző és Vizualizációs MI Asszisztens

BARNAI BALÁZS – UI092T

---

1. A projekt célja és a megoldott probléma

A projekt egy interaktív adatelemző szoftver, amely a Mesterséges Intelligenciát (Google Gemini 2.5 Flash) használ fel a strukturált adatok (CSV, Excel) és vizuális információk (képek, diagramok) feldolgozására.

A megoldott valós probléma: A vállalati adatelemzés (Business Intelligence) során a felhasználóknak gyakran hiányzik a statisztikai tudásuk az adatok értelmezéséhez, vagy rengeteg időt töltenek a diagramok formázásával és a jelentések (PDF) összeállításával. Ez az alkalmazás egy adatelemző asszisztenst ad a felhasználó mellé, aki nemcsak értelmezi a számokat, de önállóan fel is fedezi az összefüggéseket, és letölthető kész jelentést generál.

2. Architektúra és Felhasznált Technológiák

- **Frontend és Keretrendszer:** Streamlit (memóriakezeléssel: session_state).
- **Adatfeldolgozás:** Pandas (táblázatos adatok tisztítása, statisztikák számítása).
- **Vizualizáció:** Plotly Express (interaktív diagramok) és Statsmodels (trendvonalak).
- **Mesterséges Intelligencia:** google.generativeai (Gemini 2.5 Flash API).
- **Exportálás:** FPDF (automatikus PDF jelentéskészítés) és tempfile a képek átmeneti tárolására.
- **Modularitás:** A fő alkalmazás (app.py) mellett MI diagram készítő külön modulba (ai_felfedezo.py) .

3. A Generatív MI érdemi, kreatív használata

1. **Kontextus-tudatos Chat:** Az MI a háttérben megkapja az adatok statisztikáját és a képernyőn lévő diagramok paramétereit, így pontos választ ad konkrét adatkérésekre is.
2. **Multimodális Elemzés:** A szoftver képes képek (pl. külső grafikonok) befogadására, amelyeket az MI vizuálisan kielemez és értelmez.
3. **Kód- és Utasításgenerálás (Auto-Discovery):** A 4. fülön a modell nem szöveget, hanem egy kötött JSON struktúrát generál az oszlopnevek és típusok alapján, amelyből a Python kód dinamikusan, önállóan épít fel új Plotly diagramokat.
4. **Statisztikai Értelmezés:** Az összegző statisztikát és a grafikonokat az MI közérthető, üzleti meglátásokká alakítja.

4. Prompt Engineering Minősége és Tudatossága

A projektben több különböző promptolási technikát alkalmaztam a megfelelő kimenet eléréséhez:

- **Szerepkör megadása (Persona):** Minden prompt inicializálja az MI szerepét (pl. *"Te egy precíz adatelemző asszisztens vagy..."*, *"Te egy szenior adatelemző és üzleti tanácsadó vagy..."*), ami fókuszáltabb és szakmaibb válaszokat eredményez.
- **Lépésről lépésre történő gondolkodás (Chain-of-Thought - CoT):** Az összegző jelentés generálásánál az MI explicit utasítást kap a gondolatmenet strukturálására: *"Gondold végig az elemzést lépésről lépésre: 1. Legfőbb jellemzők... 2. Anomáliák... 3. Üzleti következtetés..."*
- **Kontextus Injektálás (Context Injection):** A felhasználó rövid kérdése mögött a kód egy promptot épít fel, amely tartalmazza a képernyőn lévő diagramok címeit, tengelyeit, a korábbi MI elemzéseket, valamint az adathalmaz első 5 sorát és statisztikáját.
- **Paraméterek finomhangolása (Temperature control):** * Az általános chat funkcióknál a modell alapértelmezett, kreatívabb beállításait használjuk.
    - A JSON generáló promptnál (MI Grafikonkészítő) a temperature értékét szándékosan **0.1**-re csökkentettem, kikényszerítve a determinisztikus, precíz működést a hallucinációk és formátumhibák elkerülése végett.

5. Fejlesztési mélység és Technikai kivitelezés

- **Állapotkezelés (Session State):** pl: (st.session_state.mentett_grafikonok) így a felhasználó által létrehozott grafikonok, a chat történet és az MI elemzések megmaradnak lapozás vagy újragenerálás esetén is.
- **PDF Export:** A Plotly diagramokat a rendszer memóriában (tempfile) képpé alakítja, kikényszerítve a színes sablont (template="plotly"), hogy a sötét módú UI ellenére a nyomtatott jelentés fehér háttéren is színes és olvasható maradjon. Ezt fűzi össze az FPDF az MI szövegeivel.
- **Hibakezelés (Exception Handling):** A kód fel van készítve a tipikus hibákra:
    - Kezeli a különböző CSV kódolási hibákat (UnicodeDecodeError -> latin-1 fallback).
    - Többféle Excel formátumot támogat (xlrd és openpyxl motorokkal).
    - A JSON parser blokk lekezeli, ha az MI Markdown formátumú backtick-ekkel (```json) küldi vissza a kódblokkot.
    - A Streamlit UI nem omlik össze, ha inkompatibilis oszlopokat (pl. két szöveges mezőt) próbálunk szórásdiagramra tenni.

6. Főbb funkciók (Modulok)

1. **Adatelemző Fül:** Adatfeltöltés, manuális grafikonkészítés 10+ diagramtípussal (beleértve hőtérképet és choropleth térképet is). Beépített statsmodels trendvonalak és dinamikus MI elemzés minden grafikonhoz. Interaktív chat.
2. **Képelemző Fül:** Chat felület képfeltöltéssel.
3. **Jelentés Készítése:** Letölthető, tördelt PDF jelentés a mentett diagramokból és az MI megállapításaiból.
4. **MI Grafikonkészítő (Auto-Discovery):** A feltöltött adatbázis oszlopnevei és adattípusai alapján a Gemini önállóan kitalálja és Python kóddal legenerálja a statisztikailag legértelmesebb összefüggéseket ábrázoló diagramokat.